

§3.4 感知器

最简单的神经网络，只有一个神经元。

权重(突触)，偏置(阈值)，激活函数(细胞体) 输出为 ± 1 。

$$y = \text{sgn}(\mathbf{w}^T \mathbf{x})$$

3.4.1 参数学习

N 个样本的训练集 $\{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$, $y^{(n)} \in \{+1, -1\}$ 感知器学习算法试图找到一组参数 $\mathbf{w}^*$, s.t. 对每个样本 $(\mathbf{x}^{(n)}, y^{(n)})$ 有

$$y^{(n)} (\mathbf{w}^*)^T \mathbf{x}^{(n)} > 0, \quad \forall n \in \{1, \dots, N\}.$$

感知器的学习算法 — 错误驱动的在线学习算法

① 初始化一个权重向量 $\mathbf{w} \leftarrow \mathbf{0}$

② 若 $y \mathbf{w}^T \mathbf{x} < 0$, 则 $\mathbf{w} \leftarrow \mathbf{w} + y \mathbf{x}$

$\Rightarrow$ 感知器的损失函数为

$$L(\mathbf{w}; \mathbf{x}, y) = \max(0, -y \mathbf{w}^T \mathbf{x}).$$

$$\Rightarrow \frac{\partial L(\mathbf{w}; \mathbf{x}, y)}{\partial \mathbf{w}} = \begin{cases} 0, & \text{if } y \mathbf{w}^T \mathbf{x} > 0, \\ -y \mathbf{x}, & \text{if } y \mathbf{w}^T \mathbf{x} < 0. \end{cases}$$

算法 3.1 二分类感知器的参数学习算法

输入: 训练集 $D = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$, 最大迭代次数 T

1. 初始化: $\vec{w}_0 \leftarrow \vec{0}$, $k \leftarrow 0$, $t \leftarrow 0$;

2. repeat

3. 对训练集 D 中的样本随机排序;

4. for $n=1, \dots, N$ do

5. 选取一个样本 $(\mathbf{x}^{(n)}, y^{(n)})$;

6. if $\vec{w}_k^T (y^{(n)} \mathbf{x}^{(n)}) \leq 0$ then

7. $\vec{w}_{k+1} \leftarrow \vec{w}_k + y^{(n)} \mathbf{x}^{(n)}$;

8. $k \leftarrow k+1$;

9. end

10. $t \leftarrow t+1$;

11. if $t=T$ then break;

12. end

13. until $t=T$;

输出: $\vec{w}_k$

3.4.2 感知器的收敛性

若训练集是线性可分的, 那么感知器算法可以在有限次迭代后收敛.

若训练集不是线性可分的, 那么感知器算法不能确保收敛.

当训练集是线性可分的, 对于训练集 $D = \{(\vec{x}^{(n)}, y^{(n)})\}_{n=1}^N$, 其中 $\vec{x}^{(n)}$ 为样本的增广特征向量, $y^{(n)} \in \{-1, +1\}$, 那么存在一个正常数 γ ($\gamma > 0$) 和权重向量 $\vec{w}^*$, 且 $\|\vec{w}^*\| = 1$, 对所有 n 都满足 $(\vec{w}^*)^T (y^{(n)} \vec{x}^{(n)}) \geq \gamma$

定理 3.1 感知器的收敛性: 给定训练集 $D = \{(\vec{x}^{(n)}, y^{(n)})\}_{n=1}^N$, 令 R 为训练集中最大特征向量的模, 即

$$R = \max_n \|\vec{x}^{(n)}\|$$

若训练集 D 线性可分, 两类感知器的参数学习算法 3.1 的权重次数不超过 $\frac{R^2}{\gamma^2}$.

证: 感知器权重的更新方式为

$$\vec{w}_k = \vec{w}_{k-1} + y^{(k)} \vec{x}^{(k)}$$

其中 $\vec{x}^{(k)}$, $y^{(k)}$ 表示第 k 个错误分类的样本.

因为初始权重向量为 $\vec{0}$, 在第 k 次更新时感知器的权重向量为

$$\vec{w}_k = \sum_{i=1}^k y^{(i)} \vec{x}^{(i)}$$

分别计算 $\|\vec{w}_k\|^2$ 的上下界

$$\begin{aligned} \textcircled{1} \quad \|\vec{w}_k\|^2 &= \|\vec{w}_{k-1} + y^{(k)} \vec{x}^{(k)}\|^2 = \|\vec{w}_{k-1}\|^2 + \|y^{(k)} \vec{x}^{(k)}\|^2 + 2 y^{(k)} \vec{w}_{k-1}^T \vec{x}^{(k)} \\ &\leq \|\vec{w}_{k-1}\|^2 + R^2 \\ &\leq \|\vec{w}_{k-2}\|^2 + 2R^2 \\ &\leq \dots \\ &\leq KR^2 \end{aligned}$$

$$\begin{aligned}
 \textcircled{2} \quad \|\tilde{w}_k\|^2 &= \|\tilde{w}^*\|^2 \cdot \|\tilde{w}_k\|^2 \geq \|(\tilde{w}^*)^T \tilde{w}_k\|^2 \\
 &= \|(\tilde{w}^*)^T \sum_{k=1}^K (y^{(k)} - \hat{z}^{(k)})\|^2 \\
 &= \left\| \sum_{k=1}^K (\tilde{w}^*)^T y^{(k)} - \hat{z}^{(k)} \right\|^2 \\
 &\geq K^2 \sigma^2
 \end{aligned}$$

由①、②可知

$$\begin{aligned}
 K^2 \sigma^2 &\leq K R^2 \\
 \Rightarrow K &\leq \frac{R^2}{\sigma^2} \quad \#
 \end{aligned}$$

不足:

(1). 数据集线性可分时, 感知器虽可找到一个超平面把两类数据分开, 但不能保证其泛化能力.

(2). 感知器对样本顺序比较敏感, 每次迭代的顺序不一致时, 找到的分割平面也往往不一致. 迭代次数上排后面的错误样本比前面错误样本, 对最终的结果影响更大.

(3). 若训练集不是线性可分的, 则永远不会收敛.

3.4.3 参数平均感知器

为提高感知器的鲁棒性和泛化能力，可将在感知器学习过程中的所有 K 个权重向量保存起来，并赋予每个权重向量一个置信系数 Q_k ($1 \leq k \leq K$)。最终分类结果通过这 K 个不同权重的感知器投票决定。——投票感知器。

令

① T_k ：第 k 次更新权重时的迭代次数（即训练过的样本数量）， T_{k+1} 为下次权重更新时的迭代次数。

② 权重向量的置信系数 Q_k 设置为从 T_k 到 T_{k+1} 之间间隔的迭代次数，即 $Q_k = T_{k+1} - T_k$ 。 Q_k 越大，说明权重向量在之后的训练过程中正确分类样本的数量越多，越值得信赖。

$$\hat{y} = \text{sgn} \left(\sum_{k=1}^K Q_k \text{sgn}(\mathbf{w}_k^T \mathbf{z}) \right)$$

投票感知器要保存 K 个权重向量，会有额外的开销。常用简化版本——平均感知器。

$$\hat{y} = \text{sgn} \left(\frac{1}{T} \sum_{k=1}^K Q_k (\mathbf{w}_k^T \mathbf{z}) \right)$$

$$= \text{sgn} \left(\frac{1}{T} \left(\sum_{k=1}^K Q_k \mathbf{w}_k^T \right) \mathbf{z} \right)$$

$$= \text{sgn} \left(\left(\frac{1}{T} \sum_{k=1}^T \mathbf{w}_k^T \right) \mathbf{z} \right)$$

$$= \text{sgn}(\bar{\mathbf{w}}^T \mathbf{z})$$

T 为迭代总次数， $\bar{\mathbf{w}}$ 为 T 次迭代的平均权重向量。

算法3.2 改进的平均感知器学习算法

输入: 训练集 $\{(\vec{x}^{(n)}, y^{(n)})\}_{n=1}^N$, 最大迭代次数 T

1. 初始化: $\vec{w} \leftarrow 0$, $\vec{u} \leftarrow 0$, $t \leftarrow 0$;

2. repeat

3. 对训练集样本随机排序;

4. for $n = 1, \dots, N$ do

5. 选取一个样本 $(\vec{x}^{(n)}, y^{(n)})$;

6. 计算预测类别 $\hat{y}_c$;

7. if $\hat{y} \neq y^{(n)}$ then

8. $\vec{w} \leftarrow \vec{w} + y^{(n)} \vec{x}^{(n)}$;

9. $\vec{u} \leftarrow \vec{u} + t y^{(n)} \vec{x}^{(n)}$;

10. end

11. $t \leftarrow t + 1$;

12. if $t = T$ then break;

13. end

14. until $t = T$;

15. $\vec{w} = \vec{w}_T - \frac{1}{T} \vec{u}$;

输出: $\vec{w}$

$\vec{z}_1, \dots, \vec{z}_k$

$\vec{w}_c$

$\vec{u}_c$

0

0

$y^{(i_1)} \vec{x}^{(i_1)}$

$\vec{z}_1 y^{(i_1)} \vec{x}^{(i_1)}$

$y^{(i_1)} \vec{x}^{(i_1)} + y^{(i_2)} \vec{x}^{(i_2)}$

$\vec{z}_1 y^{(i_1)} \vec{x}^{(i_1)} + \vec{z}_2 y^{(i_2)} \vec{x}^{(i_2)}$

$\vdots$

$\sum_{k=1}^K y^{(i_k)} \vec{x}^{(i_k)}$

$\sum_{k=1}^K \vec{z}_k y^{(i_k)} \vec{x}^{(i_k)}$

$$\vec{w}_T - \frac{1}{T} \vec{u} = \sum_{k=1}^K y^{(i_k)} \vec{x}^{(i_k)} - \frac{1}{T} \sum_{k=1}^K \vec{z}_k y^{(i_k)} \vec{x}^{(i_k)}$$

$$= \frac{1}{T} \sum_{k=1}^K (T - \vec{z}_k) y^{(i_k)} \vec{x}^{(i_k)}$$

$$= \frac{1}{T} \sum_{k=1}^K (T-1 - (\vec{z}_k - 1)) y^{(i_k)} \vec{x}^{(i_k)}$$

$$= \frac{1}{T} \sum_{k=1}^K \sum_{c=0}^{T-1} 1_{[t \geq \vec{z}_k]} y^{(i_k)} \vec{x}^{(i_k)}$$

$$= \frac{1}{T} \sum_{c=0}^{T-1} \sum_{k=1}^K 1_{[\vec{z}_k \leq t]} y^{(i_k)} \vec{x}^{(i_k)}$$

$$= \frac{1}{T} \sum_{c=0}^{T-1} \vec{w}_c$$

7.4.4 扩展到多分类

在联合特征空间中，建立广义的感知器模型

$$\hat{y} = \arg \max_{\bar{y} \in \text{Gen}(x)} w^T \phi(x, \bar{y})$$

$\text{Gen}(x)$ 表示输入 x 所有的输出目标集合

C 分类问题， $\bar{y} \in \{0, 1\}^C$ one-hot 向量表示。常用的特征函数 $\phi(x, \bar{y})$ 是 x 和 $\bar{y}$ 的外积，即

$$\phi(x, \bar{y}) = \text{vec}(x \bar{y}^T) \in \mathbb{R}^{(D \times C)}$$

$\downarrow$ $\downarrow$
 $(D \times C)$ 维向量 1 维标量

给定样本 $(x, \bar{y})$ ， $x \in \mathbb{R}^D$ ， $\bar{y}$ 为第 i 维是 1 的 one-hot 向量， $\bar{y}$

$$\bar{y} = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \rightarrow i$$

则

$$\phi(x, \bar{y}) = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ x_i \\ \vdots \\ x_D \\ 0 \\ \vdots \\ 0 \end{pmatrix} \begin{matrix} \rightarrow \text{第 } (i-1)D+1 \text{ 行} \\ \rightarrow \text{第 } iD \text{ 行} \end{matrix}$$

第3.3 广义感知机学习算法

输入: 训练集 $\{(\vec{x}^{(n)}, \vec{y}^{(n)})\}_{n=1}^N$, 最大迭代次数 T

1. 初始化: $\vec{w}_0 \leftarrow 0, k \leftarrow 0, t \leftarrow 0$;
 2. repeat
 3. 对训练集 D 中的样本随机排序;
 4. for $n = 1, \dots, N$ do
 5. 选取一个样本 $(\vec{x}^{(n)}, \vec{y}^{(n)})$;
 6. 计算 $\hat{y} = \arg \max_{\vec{y}} \phi(\vec{x}^{(n)}, \vec{y})$
 7. if $\hat{y}^{(n)} \neq \vec{y}^{(n)}$ then
 8. $\vec{w}_{k+1} \leftarrow \vec{w}_k + (\phi(\vec{x}^{(n)}, \vec{y}^{(n)}) - \phi(\vec{x}^{(n)}, \hat{y}^{(n)}))$;
 9. $k \leftarrow k + 1$;
 10. end
 11. $t = t + 1$
 12. if $t = T$ then break;
 13. end
 14. until $t = T$;
- 输出 $\vec{w}_k$

3.4.4.1 广义感知器的收敛性

定义3.3 广义线性可分: 对于训练集 $D = \{(\mathbf{x}^{(n)}, \mathbf{y}^{(n)})\}_{n=1}^N$, 若存在一个正常数 $\gamma (\gamma > 0)$ 和权重 $\mathbf{w}^*$, 且 $\|\mathbf{w}^*\| = 1$, 对所有 n 都满足

$$\langle \mathbf{w}^*, \phi(\mathbf{x}^{(n)}, \mathbf{y}^{(n)}) \rangle - \langle \mathbf{w}^*, \phi(\mathbf{x}^{(n)}, \bar{\mathbf{y}}) \rangle \geq \gamma, \quad \mathbf{y} \neq \bar{\mathbf{y}}^{(n)}$$

$\phi(\mathbf{x}^{(n)}, \mathbf{y}^{(n)}) \in \mathbb{R}^D$ 为样本 $\mathbf{x}^{(n)}, \mathbf{y}^{(n)}$ 的联合特征向量. 那么训练集 D 在联合特征向量空间中是线性可分的.

广义感知器收敛性定义

定理3.2 广义感知器收敛性: 若训练集 $D = \{(\mathbf{x}^{(n)}, \mathbf{y}^{(n)})\}_{n=1}^N$ 是广义线性可分的, 并令 R 是所有样本中真实标签和错误标签在特征空间中 $\phi(\mathbf{x}, \mathbf{y})$ 最远的距离. 即

$$R = \max_n \max_{\mathbf{y} \neq \mathbf{y}^{(n)}} \|\phi(\mathbf{x}^{(n)}, \mathbf{y}^{(n)}) - \phi(\mathbf{x}^{(n)}, \bar{\mathbf{y}})\|$$

那么广义感知器参数学习算法 3.3 的权重更新次数不超过 $\frac{R^2}{\gamma^2}$.

证: $\mathbf{w}_k = \mathbf{w}_{k-1} + (\phi(\mathbf{x}^{(k)}, \mathbf{y}^{(k)}) - \phi(\mathbf{x}^{(k)}, \bar{\mathbf{y}}^{(k)}))$, $\mathbf{w}_0 = \mathbf{0}$.

$$\Rightarrow \mathbf{w}_k = \sum_{t=1}^k [\phi(\mathbf{x}^{(t)}, \mathbf{y}^{(t)}) - \phi(\mathbf{x}^{(t)}, \bar{\mathbf{y}}^{(t)})]$$

$$\begin{aligned} \textcircled{1} \quad \|\mathbf{w}_k\|^2 &= \|\mathbf{w}_{k-1} + (\phi(\mathbf{x}^{(k)}, \mathbf{y}^{(k)}) - \phi(\mathbf{x}^{(k)}, \bar{\mathbf{y}}^{(k)}))\|^2 \\ &= \|\mathbf{w}_{k-1}\|^2 + \|\phi(\mathbf{x}^{(k)}, \mathbf{y}^{(k)}) - \phi(\mathbf{x}^{(k)}, \bar{\mathbf{y}}^{(k)})\|^2 \\ &\quad + 2 \mathbf{w}_{k-1}^T [\phi(\mathbf{x}^{(k)}, \mathbf{y}^{(k)}) - \phi(\mathbf{x}^{(k)}, \bar{\mathbf{y}}^{(k)})] \end{aligned}$$

$$\leq \|\mathbf{w}_{k-1}\|^2 + R^2$$

$$\leq \dots$$

$$\leq k R^2$$

$$\begin{aligned}
 \textcircled{2} \quad \|\vec{w}_k\|^2 &= \|\vec{w}^*\|^2 \cdot \|\vec{w}_k\|^2 \geq \|\vec{w}^{*T} \vec{w}_k\|^2 \\
 &= \left\| \vec{w}^{*T} \cdot \sum_{k=1}^K [\phi(\vec{x}^{(k)}, \vec{y}^{(k)}) - \phi(\vec{x}^{(k)}, \hat{\vec{y}}^{(k)})] \right\|^2 \\
 &= \left\| \sum_{k=1}^K \vec{w}^{*T} [\phi(\vec{x}^{(k)}, \vec{y}^{(k)}) - \phi(\vec{x}^{(k)}, \hat{\vec{y}}^{(k)})] \right\|^2 \\
 &\geq \left\| \sum_{k=1}^K \gamma \right\|^2 \\
 &= K^2 \gamma^2
 \end{aligned}$$

$$\text{故 } K^2 \sigma^2 \leq KR^2 \Rightarrow K \leq \frac{R^2}{\sigma^2}. \quad \#$$