

§3.5 支持向量机 SVM

SVM 找到分割超平面有更好鲁棒性.

给定二分类数据集 $D = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$, $y^{(n)} \in \{-1, +1\}$. 若两类样本是可分的, 即存在一个超平面

$$\bar{\mathbf{w}}^T \mathbf{x} + b = 0$$

将两类样本分开, 那么对于每个样本都有 $y^{(n)}(\bar{\mathbf{w}}^T \mathbf{x}^{(n)} + b) > 0$.

数据集 D 中每个样本 $\mathbf{x}^{(n)}$ 到分割超平面的距离为:

$$\gamma^{(n)} = \frac{|\bar{\mathbf{w}}^T \mathbf{x}^{(n)} + b|}{\|\bar{\mathbf{w}}\|} = \frac{y^{(n)}(\bar{\mathbf{w}}^T \mathbf{x}^{(n)} + b)}{\|\bar{\mathbf{w}}\|}$$

定义间隔:

$$\gamma = \min_n \gamma^{(n)}$$

γ 越大, 则分割超平面的划分更稳定. SVM 目标就是寻找一个超平面 $(\bar{\mathbf{w}}^*, b^*)$, s.t.

γ 最大. 即

$$\max_{\bar{\mathbf{w}}, b} \gamma \quad \text{s.t.} \quad \frac{y^{(n)}(\bar{\mathbf{w}}^T \mathbf{x}^{(n)} + b)}{\|\bar{\mathbf{w}}\|} \geq \gamma, \quad \forall n \in \{1, 2, \dots, N\}.$$

注意到同时缩放 $\bar{\mathbf{w}} \rightarrow k\bar{\mathbf{w}}$ 和 $b \rightarrow kb$ 不会改变 $\mathbf{x}^{(n)}$ 到分割超平面的距离, 可限制 $\|\bar{\mathbf{w}}\| \cdot \gamma = 1$. 则也等价于

$$\max_{\bar{\mathbf{w}}, b} \frac{1}{\|\bar{\mathbf{w}}\|} \quad (*)$$

$$\text{s.t.} \quad y^{(n)}(\bar{\mathbf{w}}^T \mathbf{x}^{(n)} + b) \geq 1.$$

数据集中所有满足 $y^{(n)}(\bar{\mathbf{w}}^T \mathbf{x}^{(n)} + b) = 1$ 的样本点都称为支持向量.

2.1 参数学习

将(4)的目标函数写为凸优化问题

$$\min_{\vec{w}, b} \frac{1}{2} \|\vec{w}\|^2$$

$$\text{s.t. } 1 - y^{(n)} (\vec{w}^T \vec{x}^{(n)} + b) \leq 0, \quad \forall n \in \{1, \dots, N\}$$

使用 Lagrange 乘数法

$$L(\vec{w}, b, \lambda) = \frac{1}{2} \|\vec{w}\|^2 + \sum_{n=1}^N \lambda_n (1 - y^{(n)} (\vec{w}^T \vec{x}^{(n)} + b)) \quad (1)$$

其中 $\lambda_1 \geq 0, \dots, \lambda_N \geq 0$ 为 Lagrange 乘数。令

$$\begin{cases} \frac{\partial L}{\partial \vec{w}} = \vec{w} + \sum_{n=1}^N \lambda_n (-y^{(n)} \vec{x}^{(n)}) = \vec{0} \\ \frac{\partial L}{\partial b} = \sum_{n=1}^N \lambda_n (-y^{(n)}) = 0 \end{cases}$$

$$\Rightarrow \begin{cases} \vec{w} = - \sum_{n=1}^N \lambda_n y^{(n)} \vec{x}^{(n)} & (2) \\ 0 = \sum_{n=1}^N \lambda_n y^{(n)} & (3) \end{cases}$$

将(2)代入(1), 再由(3)得

$$\begin{aligned} L &= \frac{1}{2} \left(\sum_{n=1}^N \lambda_n y^{(n)} \vec{x}^{(n)}, \sum_{m=1}^N \lambda_m y^{(m)} \vec{x}^{(m)} \right) + \\ &\quad \sum_{n=1}^N \lambda_n \left(1 - y^{(n)} \left(\left(\sum_{m=1}^N \lambda_m y^{(m)} \vec{x}^{(m)} \right)^T \vec{x}^{(n)} + b \right) \right) \\ &= \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m y^{(n)} y^{(m)} (\vec{x}^{(n)})^T \vec{x}^{(m)} + \sum_{n=1}^N \lambda_n \\ &\quad - \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m y^{(n)} y^{(m)} (\vec{x}^{(n)})^T \vec{x}^{(m)} \\ &= -\frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \lambda_n \lambda_m y^{(n)} y^{(m)} (\vec{x}^{(n)})^T \vec{x}^{(m)} + \sum_{n=1}^N \lambda_n \\ &\triangleq T(\lambda) \end{aligned}$$

设

$$Z \triangleq \begin{bmatrix} y^{(1)} (\vec{x}^{(1)})^T \\ \vdots \\ y^{(N)} (\vec{x}^{(N)})^T \end{bmatrix}, \quad Q \triangleq Z Z^T$$

对 $\forall v \in \mathbb{R}^N$,

$$v^T Q v = v^T Z Z^T v = \|Z^T v\|_2^2 \geq 0$$

$\Rightarrow Q$ 为半正定阵. 故 f 为半双凸 $\Rightarrow f$ 为 λ 的凸函数.

利用凸优化方法求解得到最优值 λ^* . 优化方法: SMO 算法.

由 KKT 条件中的互补松弛条件, 最优解满足

$$\lambda_n^* (1 - y^{(n)} (w^* z^{(n)} + b^*)) = 0.$$

若样本 $z^{(n)}$ 不在约束边界上, $\lambda_n^* = 0$, 其约束失效; 若样本 $z^{(n)}$ 在约束边界上, $\lambda_n^* > 0$.

在计算出 λ^* 后, 由 (2) 可得 w^* . 最优偏置 b^* 可通过任意一个支持向量 (z, y) 计算得到:

$$b^* = y - (w^* z).$$

最优参数的 SVM 决策函数:

$$f(z) = \text{sgn} (w^* z + b^*)$$

$$= \text{sgn} \left(\sum_{n=1}^N \lambda_n^* y^{(n)} (z^{(n)})^T z + b^* \right)$$

⌞ 只依赖于 $\lambda_n^* > 0$ 的样本点——支持向量.

$\rightarrow$ 分类速度快.

3.3.2 核函数

SVM 可以使用核函数隐式将样本从原始特征空间映射到更高维空间, 解决原始特征函数线性不可分问题.

比如在变换后的特征空间中, SVM 决策函数为

$$\begin{aligned} f(x) &= \text{sgn}(\omega^T \phi(x) + b^*) \\ &= \text{sgn}\left(\sum_{i=1}^n \alpha_i y_i k(x^{(i)}, x) + b^*\right), \end{aligned}$$

其中 $k(x, z) = \phi(x)^T \phi(z)$

通常不需要显式地给出 $\phi(x)$ 具体形式, 可通过核技巧构造. 以 $x, z \in \mathbb{R}^2$ 为例, 构造

$$k(x, z) = (x^T z + 1)^2 = \phi(x)^T \phi(z)$$

来隐式^地计算 x, z 在特征空间 ϕ 中内积. 其中

$$\phi(x) = [1, \sqrt{2}x_1, \sqrt{2}x_2, \sqrt{2}x_1x_2, x_1^2 + x_2^2]^T.$$

3.5.3 软间隔

若训练集中样本在特征空间中不是线性可分的，就无法找到最优解。为了容忍部分不满足约束的样本，可引入松弛变量 ξ_n ，将优化问题变为

$$\begin{aligned} \min_{\vec{w}, b} & \frac{1}{2} \|\vec{w}\|^2 + C \sum_{n=1}^N \xi_n \\ \text{s.t.} & 1 - y^{(n)} (\vec{w}^T \vec{x}^{(n)} + b) - \xi_n \leq 0, \quad \forall n \in \{1, \dots, N\} \\ & \xi_n \geq 0, \quad \forall n \in \{1, 2, \dots, N\}. \end{aligned} \quad (*)$$

其中参数 $C > 0$ 用来控制间隔和松弛变量惩罚的平衡。引入松弛变量的间隔称为软间隔。

公式 (*) 也可表示为经验风险 + 正则化项的形式：

$$\min_{\vec{w}, b} \sum_{n=1}^N \max(0, 1 - y^{(n)} (\vec{w}^T \vec{x}^{(n)} + b)) + \frac{1}{2C} \|\vec{w}\|^2,$$

其中 $\max(0, 1 - y^{(n)} (\vec{w}^T \vec{x}^{(n)} + b))$ 看作损失函数，称为 Hinge 损失函数